

Graph-Based Vector Search: 状態-オブ-ジ-アートの実験評価

エグゼクティブサマリ

本論文では、グラフベースの近似ベクトル検索手法を対象に、主要手法の設計パラダイムを整理し、12種の最先端アルゴリズムを用いて実験的评价を行っています【2 + L59-L66】。データセットには最大10億ベクトルを含む7種類を用い、特に「インクリメンタル挿入 (Incremental Insertion)」「近傍多様化

(Neighborhood Diversification)」の二つのパラダイムを組み合わせた手法が優れた性能を示すことを確認しました【2 + L59-L66】。例えば、HNSW は層状構造と多様化を組み合わせることで高速検索を実現し、ELPIS は分割統治 + 挿入 + 多様化で1B規模データにおいて高性能でした【12 + L703-L708】【17 + L1250-L1258】。まとめとして、効果的なシード選択とグラフ多様化の重要性が指摘され、今後はデータ特性に応じた手法のハイブリッド化や高速化が課題とされています【9 + L1419-L1426】【9 + L1429-L1438】。

背景・目的

高次元ベクトル検索は推薦、情報検索、クラスタリング、分類など多くの応用に不可欠です【2 + L12-L20】。近年の学習埋め込みモデルの普及でベクトルデータは数十億点・数千次元に達し、総当たり走査では計算量が prohibitive になります【2 + L12-L20】【3 + L66-L75】。そこで、多くの手法が「近似 (approximate) 検索」によって高速化を図っており、特に**グラフベース手法**は厳密性を緩めるタスクで低レイテンシを実現する有力な方法となっています【2 + L12-L20】【3 + L66-L75】。本研究の目的は、このグラフベース近似探索手法群を体系的に整理し、その設計思想 (パラダイム) を明らかにするとともに、大規模データ上での性能特性を明示することです【2 + L59-L66】【10 + L472-L481】。

手法概要と設計パラダイム

グラフベース手法では、データセットの各点を頂点とするグラフを構成し、類似した点同士を辺で接続します【10 + L422-L430】。クエリ回答時にはビームサーチ (幅優先探索) を用い、適切な初期ノードから探索を開始して近傍ノードを取得します (アルゴリズム例 (擬似コード)【10 + L442-L451】)。論文では**5つの主要な設計パラダイム**を定義・分類しています【3 + L168-L177】【10 + L472-L481】：

- **Seed Selection (SS, シード選択)**：検索開始点 (エントリノード) を決定する方法。ランダムに選ぶものから、階層構造 (例：HNSWの層状グラフ) やKD木・LSHなどの補助構造を用いる手法まで多様です【10 + L472-L481】【11 + L531-L540】。
- **Neighborhood Propagation (NP, 近傍伝播)**：既存のグラフを反復的に改良する戦略。初期グラフに対してNN-Descentのように近傍間の相互伝播を繰り返し、グラフの近似k-NN性を高めます【10 + L483-L490】。
- **Incremental Insertion (II, インクリメンタル挿入)**：データ点を一つずつグラフに逐次追加して構築する手法。追加時にビームサーチで最も近い既存ノードとリンクし、スモールワールド特性 (近傍と遠方ノードを繋ぐ長距離リンク) を生み出します【10 + L490-L498】。
- **Neighborhood Diversification (ND, 近傍多様化)**：各ノードの余計な近傍エッジを削減しグラフを疎化する手法。例えばRND (相対近傍多様化) では、より近いノードに隣接するエッジを排除し、遠方へのリンクを確保します【10 + L501-L508】【12 + L640-L649】。これによりグラフがスパースになり、検索時の冗長比較が減少します【10 + L501-L508】。

- **Divide-and-Conquer (DC, 分割統治)**：データセットを複数の部分集合に分割し、それぞれ独立したグラフを構築する戦略。例えば SPTAG は全データをクラスタに分け、各クラスタで部分グラフを構築してから検索します【10 + L509-L514】。ELPIS は部分グラフを並列検索するアプローチです。

これらのパラダイムは排他的ではなく、手法ごとに組み合わせで利用します。例えば、HNSW (2020) は「II + ND」、DPG (2019) は主に「ND」を採用しており【12 + L686-L694】、ELPIS (2023) は「DC + II + ND」を組み合わせています【12 + L703-L708】。




図: グラフ検索の流れ (クエリ → シード選択 → ビームサーチ → 近傍ノード) ※ビームサーチの基本アルゴリズム【10 + L442-L451】に基づく。

手法の分類と発展タイムライン

図3に示すように、グラフベース手法は前述5パラダイムに分類できます【12 + L674-L683】。例えば **NSW** (2011) はIncremental Insertionに基づく手法で、**HNSW** (2020) は層状構造 + RNDを利用する手法です【12 + L686-L694】。**DPG** (Diversified Proximity Graph, 2019) はKGraphのグラフをMONDで多様化し、**NSG/SSG** (2019/2021) はEFANNAグラフにRNDを適用します【12 + L686-L694】。以下に代表手法の登場年を示します：




図: 主要なグラフベース探索手法の登場年 (タイムライン)。HNSW, Vamana, ELPIS などが近年に提案されています【12 + L686-L694】 【17 + L1250-L1258】。

実験設定

評価には7種類の実データセット (例: Deep ネットワーク埋め込み、SIFT、SALD、Seismicなど) を用い、各データセットは1M~10億ベクトル (最大データ量350GB) に拡張しました【2 + L59-L66】 【16 + L1141-L1150】。検証対象は12種の最先端グラフベース手法で、すべてRecall0.99を目標としてインデックス構築時間・メモリ消費および検索に必要な距離計算回数などを比較しました【2 + L59-L66】 【16 + L1141-L1150】。また、前節で示した各パラダイム (特にSeed Selection と ND) の影響を個別に評価するため、ND手法の比較やSS戦略の実験も行っています。実験結果の詳細は以下の通りです。

実験結果

- **近傍多様化 (ND) の効果**：Deep25GBとSIFT25GBデータで各多様化手法の剪定率を比較したところ、RNDが最も高い剪定率 (Deepで20%、SIFTで25%) を示しました【14 + L1052-L1060】。MONDは中程度の剪定 (2~4%)、RRNDは最も低い剪定率 (0.6~0.7%) でした【14 + L1052-L1060】。つまり、RNDはグラフを大幅に疎化 (サイズ縮小) しメモリ削減に寄与し、RRNDはグラフサイズが大きめになる傾向があります【14 + L1052-L1060】。

- ・**シード選択 (SS) の効果**：Stacked-NSW (SN) とランダムK点 (KS) の2手法が検索効率で最良であり、Medoid (MD) や固定ランダム (SF) は最も効率が低い結果でした【14 + L1081-L1090】。データサイズが中～小規模 (≤25GB) の場合、KSがSNをやや上回る傾向にありますが、1B規模ではSNが優位になります【14 + L1090-L1099】。これはKSがクエリ近傍領域の代表点を十分含めるにはサンプル数を増やす必要がある一方、SNはデータ増加に対してログスケールで層を広げられるためと考えられます【14 + L1090-L1099】。また、インデックス構築時にはSNはKSに比べて大幅に多くの距離計算を要し、KSベースのインデックスはSNが完成する前に多数のクエリ (例：Deep25GBで約117万クエリ) に回答可能でした【14 + L1110-L1118】。
- ・**インデックス構築性能**：全体として、Incremental Insertionベースの手法が最も高速にインデックスを構築できました。特に、DC+IIベースのELPISは1M/25GBでHNSWの約2.7倍、NSGの4倍高速でした【16 + L1156-L1164】。逆に、SPTAG-BKT/KDTは25GBの構築に25時間以上かかり、ELPISより24倍遅いという低速さを示しました【16 + L1156-L1164】。Deep100GB以上の規模では、HNSW・Vamana・ELPISの3手法のみが実用的な時間で構築可能であり、その中でもELPISがHNSWの2倍、Vamanaの2.7倍高速でした【16 + L1165-L1168】。メモリ消費ではELPISが最小で、HNSWと比較して約40%少ない使用量となりました【16 + L1174-L1180】。一方、HNSWは高速化の代償として大きな連続メモリ領域を確保する実装を採用しており、大規模時にメモリ負荷が増大します【16 + L1174-L1180】。
- ・**検索性能**：大規模データにおいてはELPISが一貫して最高性能を示しました。特にDeep1Bデータでは、リコール0.95達成に要する時間で他法を最大10倍上回りました【17 + L1250-L1258】。また、検索時のメモリ消費はVamanaとELPISが最も小さく、ELPISは小さいビーム幅で高精度を得られる傾向にありました【16 + L1218-L1225】。その他、NSG/SSGも高精度では良好な性能を見せましたが、EFANNA依存のため大規模で構築困難となり除外されました【17 + L1339-L1348】。

考察

実験結果から以下の洞察と今後の課題が得られました：

- ・**インデックス構築のスケーラビリティ課題**：多くの手法は25GB以上の構築に時間やメモリの制約がありました【9 + L1387-L1396】。特にEFANNAベースのNSG/SSGやHCNNG, SPTAG (BKT/KDT) は25-100GBの構築すら非現実的であり、今後は構築過程での要約技術や効率的な基底グラフ (例：IVFPQ など) の活用が期待されます【9 + L1387-L1396】。
- ・**近傍多様化の効果**：どの規模でもND戦略を用いると検索性能は向上しましたが、特にRNDとMONDが最良の結果を示しました【9 + L1410-L1418】。しかし、実際の最適な剪定強度やノード間隔の理論的トレードオフについては未解明であり、さらなる研究が必要です【9 + L1410-L1418】。
- ・**シード選択の重要性**：SS戦略は検索効率だけでなくインデックス構築にも影響し、効果的な戦略が重要であることが示されました【9 + L1419-L1426】。現状の手法ではSNとKSが優位でしたが、固定シードや中点選択は性能が劣ります【14 + L1081-L1090】【9 + L1419-L1426】。今後はより軽量かつデータ適応的なシード選択手法の研究が求められます【9 + L1419-L1426】。
- ・**データ適応手法**：実験上、IIパラダイムは構築効率・拡張性で優れ、NDパラダイムは検索性能で優れていました。一方、DCパラダイムはシードが難しい困難データ (高LID/低RCデータセット) で有利でした【9 + L1428-L1437】。したがって、データの分布特性 (次元、局所密度、ワークロード特性など) に応じてパラダイムを組み合わせる「データ適応的」手法が今後の方向性です【9 + L1428-L1437】。
- ・**ハイブリッド設計**：実際の最先端手法は複数のパラダイムを組み合わせしており、例えばHNSWはII+RND、ELPISはDC+II+ND、VamanaはND+階層的な手法などです【12 + L686-L694】【9 + L1441-L1449】。これらの結果から、今後はII, ND, DCの長所を同時に活かすハイブリッド手法や、新しい基盤グラフ・クラスタリング手法の開発が期待されます【9 + L1441-L1449】。
- ・**最適化実装**：一部の手法はC++最適化ライブラリ (parlayNNなど) を用いると大幅に性能が向上します【9 + L1452-L1456】。今後はこのような低レベル最適化や並列化によるスケーラビリティの向上も重要な研究課題です。

結論と将来課題

本研究では、メモリ内グラフベース近似ベクトル検索手法の現状をサーベイし、新たに5つの設計パラダイムによるタクソノミーを提案しました【8＋L1474-L1482】。そして7種類の大規模データセット（最大1Bベクトル）を用いて12手法を評価し、設計選択が性能に及ぼす影響を明らかにしました【8＋L1474-L1482】

【8＋L1480-L1487】。実験の結果、インクリメンタル挿入（II）ベースの手法が最も拡張性に優れ、近傍多様化（ND）が検索性能を大幅に向上させることが確認されました【8＋L1480-L1487】。結論として、効率的なシード選択とグラフ多様化戦略の開発は引き続き重要であり、特に**データ適応的手法**や**ハイブリッド構造**の探索、索引構築のさらなる効率化が将来の課題とされています【8＋L1480-L1487】【9＋L1428-L1437】。

スライド構成案

以下は提案するパワーポイントスライドの構成例です（各スライド見出しと要点）：

1. **タイトルスライド**：論文タイトルと著者名、発表会議/年月
2. **エグゼクティブサマリ**：本研究の目的・手法・結果の概略【2＋L59-L66】【8＋L1474-L1482】
3. **背景・動機**：ベクトル検索の応用、大規模化の課題【2＋L12-L20】
4. **グラフベース探索の概要**：近傍グラフとビームサーチの原理【10＋L422-L430】【10＋L442-L451】
5. **設計パラダイム**：5つのパラダイム（SS, NP, II, ND, DC）と説明【3＋L168-L177】【10＋L472-L481】
6. **主な手法の分類**：代表手法と組み合わせパラダイム（例：HNSW, Vamana, ELPIS）【12＋L686-L694】【12＋L703-L708】
7. **手法間タイムライン**：主要手法の登場年タイムライン（図）【12＋L686-L694】
8. **実験設定**：使用データセット、手法群、評価指標の説明【2＋L59-L66】【16＋L1141-L1150】
9. **近傍多様化の結果**：RND/RRND/MONDの剪定効果（表/グラフ）【14＋L1052-L1060】
10. **シード選択の結果**：SN/KSなどの検索効率比較（グラフ）【14＋L1081-L1090】【14＋L1090-L1099】
11. **インデックス構築性能**：構築時間・メモリ比較（図表）【16＋L1156-L1164】【16＋L1174-L1180】
12. **検索性能（小規模）**：1Mデータでのクエリ速度（グラフ）【17＋L1237-L1245】
13. **検索性能（大規模）**：25GB～1Bデータでの比較（グラフ）【17＋L1250-L1258】
14. **考察**：主要結果のまとめと洞察【9＋L1410-L1418】【9＋L1419-L1426】
15. **結論・将来課題**：提案のまとめと今後の研究方向【8＋L1480-L1487】【9＋L1428-L1437】
16. **参考文献**：引用文献リスト

参考文献

- I. Azizi, K. Echihiabi, T. Palpanas, “Graph-Based Vector Search: An Experimental Evaluation of the State-of-the-Art,” SIGMOD 2025（査読論文）【2＋L59-L66】
- D. Malkov, D. Yashunin, “Efficient and Robust Approximate Nearest Neighbor Search using Hierarchical Navigable Small World Graphs,” NeurIPS 2020.
- K. Li et al., “Diversified Proximity Graph for Scalable Approximate Nearest Neighbor Search,” ICML 2019.
- P. Fu et al., “Navigating Spreading-out Graph for Approximate Nearest Neighbor Search,” NeurIPS 2019.
- S. Chen et al., “SPTAG: A Static Partition Tree and Graph Based Search Library,” PVLDB 2018.
- (その他、Seed選択に関する文献や、元論文の参考文献参照)

以上をまとめたPowerPoint資料（スライド各枚に図表と注釈付き）が `graph_search_presentation.pptx` として作成されています。必要に応じてダウンロードしてご活用ください。